



**GOBIERNO DE
MÉXICO**

EDUCACIÓN
SECRETARÍA DE EDUCACIÓN PÚBLICA



**TECNOLÓGICO
NACIONAL DE MÉXICO**



Tecnológico Nacional de México Campus Ciudad Juárez

Estudiantes: EQUIPO 3

- Carlos Daniel Pérez Noriega 22111321 -

Jazmin Mendoza Martinez 22111729

Carrera: Ingeniería en Sistemas Computacionales. / Ingeniería en
Tecnologías de la Información y Comunicaciones.

Materia: Analítica de Datos

Nombre del proyecto: “Factores Socioeconómicos que Predicen el Índice
de Felicidad de un País: Un Enfoque de Regresión”

Docente: Dora Ivette Rivero Caraveo

Periodo: Ago–Dic 2025

Contenido

2. RECORDATORIO DEL PROYECTO ORIGINAL.....	3
3. MARCO TEÓRICO.....	4
4. DESARROLLO DEL PROYECTO	6
5. RESULTADOS Y CONCLUSIONES	12
REFERENCIAS.....	14

2. RECORDATORIO DEL PROYECTO ORIGINAL

La idea general de este proyecto es tratar de entender qué hace que un país sea más “feliz” que otro, pero no desde la opinión o la intuición, sino apoyándonos en datos reales y en modelos de regresión. Para eso usamos los datos del **World Happiness Report 2019** y construimos modelos que intentan predecir el índice de felicidad de cada país a partir de distintos factores socioeconómicos.

El título completo del proyecto es:

“Factores socioeconómicos que predicen el índice de felicidad de un país: un enfoque de regresión”.

El objetivo general que guía todo el trabajo se puede resumir así:

Predecir el índice de felicidad de un país usando variables como el PIB per cápita, el apoyo social, la esperanza de vida saludable, la libertad para tomar decisiones, la generosidad y la percepción de corrupción; y, a partir de eso, identificar cuáles de esas variables parecen influir más en la felicidad reportada por la población.

La pregunta guía que nos acompañó durante el proyecto fue:

¿Qué factores influyen directamente en el índice de felicidad de un país y hasta qué punto podemos predecir ese índice usando un modelo de regresión?

Esta pregunta nos ayudó a tomar decisiones tanto en la parte de análisis exploratorio como en la selección y comparación de modelos.

El dataset que utilizamos es la versión **2019 del World Happiness Report**, disponible en Kaggle. Incluye alrededor de 156 países y, para cada uno, un puntaje de felicidad (**HappinessScore**) y varias variables explicativas. Entre las más importantes están:

- **GDP_per_capita**: una medida del ingreso promedio por persona.
- **Social_support**: qué tanto siente la población que puede contar con alguien en momentos difíciles.
- **Healthy_life_expectancy**: años de expectativa de vida saludable.
- **Freedom**: percepción de libertad para tomar decisiones importantes sobre la vida.
- **Generosity**: nivel percibido de generosidad en el país.
- **Corruption**: percepción sobre la corrupción en gobierno y negocios.

Este conjunto de datos nos plantea un **problema de regresión supervisada**, porque la variable objetivo (**HappinessScore**) es numérica y continua, y ya conocemos el valor real para cada país. No se trata de un proyecto integrador con sensores ni hardware físico; todo el trabajo se desarrolla con datos tabulares y herramientas de analítica de datos en Python.

3. MARCO TEÓRICO

3.1 Minería de datos

La **minería de datos** es el proceso de explorar grandes conjuntos de información para descubrir patrones, relaciones y conocimiento útil. En la práctica, combina ideas de estadística, aprendizaje automático y bases de datos. La idea no es solo “ver datos”, sino encontrar estructuras que no son tan obvias a simple vista, como relaciones entre variables, grupos de observaciones similares o tendencias que se repiten.

En este proyecto utilizamos la minería de datos para entender cómo se relacionan distintas variables socioeconómicas con la felicidad de los países. Esto implica varias tareas: limpiar los datos, describirlos, visualizarlos, probar modelos y evaluar qué tan bien esos modelos explican o predicen el índice de felicidad. Un flujo de trabajo típico incluye:

- Entender el problema y formular preguntas claras.
- Obtener y preparar los datos (limpieza, selección de variables, manejo de nulos).
- Realizar un análisis exploratorio de datos (EDA).
- Probar distintas familias de modelos.
- Evaluar los resultados y reflexionar sobre las conclusiones.

3.2 Análisis exploratorio de datos (EDA) y visualización

El **análisis exploratorio de datos (EDA)** es la etapa donde nos detenemos a “conocer” el dataset con calma, antes de entrenar modelos. Aquí queremos responder preguntas básicas pero importantes: cómo se distribuye la variable objetivo, qué variables parecen estar más relacionadas con ella, si hay valores atípicos o errores, y si existen patrones que valga la pena investigar más a fondo.

La **visualización de datos** es una herramienta clave en esta etapa. En lugar de quedarnos solo con tablas o resúmenes numéricos, usamos gráficas como histogramas, diagramas de dispersión, mapas de calor de correlación y gráficas de barras para “ver” lo que está pasando. El EDA no solo sirve para entender los datos, sino también para tomar decisiones sobre qué modelos probar, qué variables mantener y qué transformaciones podrían ser necesarias.

3.3 Modelos de regresión utilizados

En el trabajo aplicamos tres modelos principales de regresión:

- **Regresión lineal múltiple**
- **Random Forest Regressor**
- **Gradient Boosting Regressor**

La **regresión lineal múltiple** es el modelo clásico para problemas de regresión. Parte de la idea de que la relación entre la variable objetivo y las variables predictoras se puede aproximar como una combinación lineal. Aunque la realidad nunca es perfectamente lineal, este modelo tiene la ventaja de ser sencillo de interpretar: los coeficientes nos dan una idea de cómo cambia el índice de felicidad cuando una variable aumenta, manteniendo las demás constantes.

Random Forest es un método de *ensemble* que combina muchos árboles de decisión. Cada árbol ve una parte diferente de los datos y de las variables, y al final todas las predicciones se

promedian. Esto suele dar modelos más robustos y menos propensos al sobreajuste que un solo árbol. Además, Random Forest permite calcular la **importancia de cada variable** de forma relativamente intuitiva.

Gradient Boosting también utiliza árboles de decisión, pero en lugar de entrenarlos de manera independiente, los va construyendo uno tras otro. Cada nuevo árbol se enfoca en corregir los errores que cometió el modelo anterior. Este enfoque tiende a lograr muy buen desempeño, aunque requiere más cuidado con los hiperparámetros para evitar sobreajuste.

3.4 Streamlit como herramienta para dashboards

Streamlit es una biblioteca de Python pensada para que alguien que hace ciencia de datos o analítica pueda convertir su notebook o script en una aplicación web interactiva sin tener que aprender desarrollo web completo. Con unas cuantas líneas de código se puede crear un panel lateral con controles, mostrar tablas, colocar gráficos y métricas, y permitir que el usuario final “juegue” con el modelo sin tocar el código.

En este proyecto usamos Streamlit para construir un **dashboard interactivo** donde se puede:

- Elegir el modelo de regresión desde un panel lateral.
- Ajustar ciertos hiperparámetros básicos.
- Consultar el dataset completo de forma interactiva.
- Ver gráficas clave de la parte de EDA.
- Comparar el desempeño de los distintos modelos.
- Hacer predicciones tanto para países del dataset como para escenarios personalizados.

3.5 Métricas de regresión: R^2 , RMSE y MAE

Como nuestro problema es de **regresión**, las métricas principales que utilizamos son:

- **R^2 (coeficiente de determinación)**: indica qué porcentaje de la variabilidad del índice de felicidad está siendo explicado por el modelo. Un R^2 cercano a 1 significa que el modelo reproduce bastante bien la variación de los datos; un valor cercano a 0 indica que el modelo no mejora mucho respecto a usar solo la media.
- **RMSE (Root Mean Squared Error)**: es la raíz del error cuadrático medio. Básicamente nos dice, en las mismas unidades del índice de felicidad, qué tan grandes son los errores promedio del modelo. Penaliza más los errores grandes, por lo que es sensible a outliers.
- **MAE (Mean Absolute Error)**: es el promedio de los errores absolutos. A diferencia del RMSE, todos los errores cuentan de forma lineal, lo que lo hace menos sensible a valores atípicos. Es una métrica fácil de interpretar: cuánto nos desviamos, en promedio, del valor real de felicidad.

3.6 Otras métricas importantes: Accuracy, F1 y Silhouette

En problemas de **clasificación**, se utilizan otras métricas que aquí no aplicamos directamente, pero que son parte del lenguaje básico de la minería de datos.

Una de las más conocidas es la **Accuracy**, que mide qué proporción de predicciones fueron correctas respecto al total de ejemplos. Es muy intuitiva, pero puede engañar cuando las clases están desbalanceadas; por ejemplo, si el 95 % de los casos son de una sola clase, un modelo que siempre predice esa clase tendría 95 % de Accuracy sin ser realmente útil.

Por eso también se utiliza la métrica **F1-score**, que combina en un solo número la precisión (*precision*) y la sensibilidad o *recall*. El F1 es útil cuando nos interesa el equilibrio entre detectar correctamente los positivos y no generar demasiados falsos positivos, especialmente en problemas donde una clase es mucho más rara que la otra.

En problemas de **clustering**, donde no tenemos etiquetas reales, se recurre a métricas como el **coeficiente de Silhouette**. Este coeficiente mide qué tan cerca están los puntos de su propio clúster comparado con otros clústeres. Valores cercanos a 1 indican clústeres bien definidos y separados, mientras que valores cercanos a 0 o negativos sugieren que la estructura de los grupos no es tan clara.

Aunque en este proyecto no usamos Accuracy, F1 ni Silhouette porque nuestro problema es de regresión, sí es importante conocerlas porque son métricas de referencia en otros tipos de modelos dentro de la minería de datos.

4. DESARROLLO DEL PROYECTO

4.1 Preparación del dataset

El primer paso fue cargar los datos desde el archivo 2019.csv usando la biblioteca **pandas**. Una vez cargado el archivo, renombramos algunas columnas para que fueran más manejables en el código y en la redacción, por ejemplo:

- "Country or region" → "Country"
- "Score" → "HappinessScore"
- "GDP per capita" → "GDP_per_capita"
- "Social support" → "Social_support"
- "Healthy life expectancy" → "Healthy_life_expectancy"
- "Freedom to make life choices" → "Freedom"
- "Generosity" → "Generosity"
- "Perceptions of corruption" → "Corruption"

Después revisamos si había valores nulos. En caso de que se presentaran, la idea general fue imputar valores numéricos con la **mediana** y valores categóricos con la **moda**, para no perder registros completos por unos cuantos datos faltantes. También revisamos la existencia de registros duplicados y posibles errores evidentes.

Para el modelado seleccionamos como **variables predictoras**:

- GDP_per_capita
- Social_support
- Healthy_life_expectancy
- Freedom
- Generosity
- Corruption


La variable objetivo es **HappinessScore**, que representa el índice de felicidad. Dividimos los datos en un conjunto de entrenamiento (80 %) y un conjunto de prueba (20 %) usando `train_test_split`. Antes de entrenar los modelos aplicamos un **escalado estándar (StandardScaler)** a las variables predictoras, con el objetivo de que todas queden en una escala similar y los algoritmos trabajen de forma más estable.

4.2 Análisis exploratorio de datos (EDA)

En la parte de EDA generamos varias visualizaciones que nos ayudaron a entender mejor el comportamiento de los datos y a justificar posteriormente los modelos utilizados.


1) Matriz de correlación

Calculamos la matriz de correlación entre HappinessScore y las variables socioeconómicas seleccionadas. La gráfica correspondiente muestra que las variables más relacionadas con la felicidad son **GDP_per_capita**, **Social_support** y **Healthy_life_expectancy**, todas con correlaciones positivas relativamente altas. Por otra parte, **Corruption** tiende a relacionarse de forma negativa con la felicidad.




2) Diagrama de dispersión PIB vs felicidad

También hicimos un diagrama de dispersión entre **GDP_per_capita** y **HappinessScore**. La nube de puntos muestra una tendencia clara: los países con mayor PIB per cápita suelen tener índices de felicidad más altos. Aunque la relación no es perfectamente lineal, el patrón general es bastante evidente y respalda la idea de que el ingreso promedio está vinculado con el bienestar.



3) Histograma del índice de felicidad

El histograma de **HappinessScore** muestra que la mayoría de los países se concentran en valores medios, aproximadamente entre 4 y 7. Hay algunos casos con niveles muy altos de felicidad (por encima de 7.5) y otros con niveles bajos (por debajo de 4), pero no son la mayoría. Esta gráfica nos ayuda a entender la distribución general del puntaje de felicidad.




4) Top 10 países más felices

Ordenamos el dataset por HappinessScore y construimos un gráfico de barras horizontales con los 10 países con mayor puntaje de felicidad. Aparecen países que suelen destacarse en el World Happiness Report, como Finlandia, Dinamarca, Noruega e Islandia. Esta gráfica sirve para identificar rápidamente quiénes son los países mejor posicionados según el índice de felicidad.



5) Relación entre corrupción y felicidad

Además de las gráficas anteriores, generamos un diagrama de dispersión entre la variable **Corruption** y **HappinessScore**. La idea fue observar si la percepción de corrupción se refleja de manera directa en los niveles de felicidad. La gráfica muestra que, en general, los países con mayor corrupción percibida tienden a ubicarse en la parte baja del eje de felicidad, mientras que los países con menor corrupción tienden a registrar niveles más altos de felicidad. Aunque la relación no es perfecta, sí refuerza la idea de que la confianza en las instituciones y en el entorno tiene un impacto real sobre el bienestar.




En conjunto, estas visualizaciones permiten tener una idea clara de cómo se comporta el índice de felicidad y qué variables parecen estar más asociadas con él antes de entrenar los modelos.

6) Distribución del índice de felicidad por región

Además de analizar las variables socioeconómicas de manera global, también resulta útil observar cómo se distribuye el índice de felicidad entre las distintas regiones del mundo. Para esto, se construyó una gráfica tipo *boxplot* donde cada caja representa la distribución de **HappinessScore** en una región específica.

En esta visualización se aprecia que algunas regiones, como *Europe* y *North America*, tienden a concentrarse en niveles más altos de felicidad, con medianas elevadas y rangos relativamente compactos. En contraste, regiones como *Sub-Saharan Africa* muestran valores de felicidad más bajos y una dispersión mayor. Esto sugiere que no solo importan los factores individuales de cada país, sino también el contexto regional en el que se encuentran.

La gráfica ayuda a comparar de manera rápida qué regiones se encuentran, en promedio, en mejores condiciones de bienestar y cuáles enfrentan mayores retos para elevar el nivel de felicidad de su población.



4.3 Modelos de regresión

Con los datos ya limpios y entendidos, pasamos a entrenar los modelos de regresión. Para mantener una comparación justa, usamos el mismo conjunto de variables predictoras en los tres modelos.

- Para la **regresión lineal múltiple**, utilizamos la clase `LinearRegression` de `scikit-learn` con los parámetros por defecto. Este modelo sirve como línea base y también como una forma sencilla de interpretar los efectos de cada variable sobre el índice de felicidad.
- Para el **Random Forest Regressor**, comenzamos con 100 árboles (`n_estimators=100`) y fijamos un `random_state=42` para reproducibilidad. Este modelo, al basarse en muchos árboles más simples, captura bien relaciones no lineales y es relativamente robusto al sobreajuste.
- En el caso de **Gradient Boosting Regressor**, también usamos 100 estimadores y un `learning_rate` de 0.1 como punto de partida. Este modelo entrena árboles de forma secuencial, tratando de corregir los errores del modelo anterior en cada iteración. Aunque es más sensible a los hiperparámetros, suele lograr muy buen desempeño cuando se ajusta correctamente.

Después de entrenar cada modelo con el conjunto de entrenamiento, los evaluamos sobre el conjunto de prueba usando las métricas **R²**, **RMSE** y **MAE**. De forma general, los resultados muestran que:

- Los tres modelos alcanzan **R²** mayores a 0.60, lo que indica que explican una proporción importante de la variación del índice de felicidad.

- Random Forest tiende a obtener el R^2 más alto y errores algo más bajos en comparación con los otros dos modelos.
- Gradient Boosting se ubica muy cerca del desempeño de Random Forest, y es probable que con una búsqueda más fina de hiperparámetros pudiera superarlo.
- La regresión lineal, aunque no es la ganadora en precisión, sigue siendo útil como modelo interpretable y como referencia para comparar los métodos más complejos.

Además de las métricas numéricas, generamos una gráfica comparando el R^2 de los tres modelos, lo que facilita visualizar cuál se desempeña mejor de forma global.

4.4 Dashboard en Streamlit

Para que el resultado del proyecto fuera más accesible y no se quedara solo en el código, desarrollamos un **dashboard interactivo en Streamlit**. La aplicación tiene la siguiente estructura:

- Un **panel lateral (sidebar)** donde el usuario puede:
 - Seleccionar el modelo de regresión (Linear Regression, Random Forest o Gradient Boosting).
 - Ajustar hiperparámetros básicos, como el número de árboles en Random Forest o el número de estimadores y el *learning_rate* en Gradient Boosting.
 - Elegir el modo de predicción: seleccionar un país del dataset o ingresar valores personalizados de las variables.
- Una pestaña de **“Vista general y KPIs”** donde:
 - Se muestran las métricas R^2 , RMSE y MAE para el modelo actualmente seleccionado, usando `st.metric`.
 - Se despliega el dataset completo en una tabla interactiva con `st.dataframe`, lo que permite revisar rápidamente la información por país.
- Una pestaña de **“Visualizaciones”** donde se presentan:
 - La matriz de correlación entre las variables.
 - La gráfica de PIB per cápita vs índice de felicidad.
 - El top de países más felices.
 - Una gráfica de barras comparando los R^2 de los modelos.
- Una pestaña de **“Predicciones”** que permite dos modos:
 - Seleccionar un país del dataset, ver su valor real de HappinessScore y comparar contra la predicción del modelo elegido.
 - Ajustar manualmente los valores de PIB, apoyo social, esperanza de vida, libertad, generosidad y corrupción mediante sliders, para construir un escenario hipotético y obtener una predicción del índice de felicidad.


La interactividad es una parte clave del dashboard: al cambiar de modelo en el panel lateral, se recalculan las métricas, se actualizan las gráficas de comparación y cambian las predicciones mostradas. De esta forma, el dashboard no es solo un reporte estático, sino una herramienta que permite explorar el impacto de las decisiones de modelado.

🔗 [Insertar aquí capturas de pantalla del dashboard en Streamlit como Figuras 7, 8, etc.]


- Figura 7: Vista general del dashboard (sidebar + KPIs).



- Figura 8: Pestaña de visualizaciones.



- Figura 9: Pestaña de predicciones.



5. RESULTADOS Y CONCLUSIONES

5.1 Hallazgos principales

A partir del análisis exploratorio y los modelos de regresión, podemos destacar varios hallazgos:

- Las variables **GDP_per_capita**, **Social_support** y **Healthy_life_expectancy** aparecen de manera consistente como las más importantes para explicar el índice de felicidad. Esto se observa tanto en las correlaciones como en la importancia de variables de los modelos basados en árboles.
- La percepción de **corrupción** (Corruption) tiende a relacionarse de forma negativa con la felicidad. En general, los países donde se percibe mayor corrupción registran índices de felicidad más bajos, aunque este efecto no es tan fuerte como el de las variables económicas y de salud.
- La **libertad para tomar decisiones** (Freedom) y la **generosidad** (Generosity) también aportan información, pero su peso parece un poco menor respecto a las variables principales. Aun así, forman parte de la combinación de factores que ayudan a perfilar mejor el nivel de bienestar.

5.2 Comparación de modelos

En términos de desempeño, los tres modelos resultaron razonablemente buenos, pero cada uno tiene sus características:

- **Random Forest** se perfila como el modelo más equilibrado entre precisión y robustez. Tiende a obtener el R^2 más alto y los errores más bajos, además de ofrecer una noción clara de la importancia de cada variable.
- **Gradient Boosting** logra resultados muy cercanos a Random Forest. Con una búsqueda más detallada de hiperparámetros (por ejemplo, usando GridSearchCV o RandomizedSearchCV) es muy probable que pueda igualarlo o incluso superarlo en algunas métricas.
- La **regresión lineal múltiple** se queda un poco por detrás en precisión, pero sigue siendo valiosa como modelo de referencia y como herramienta para explicar, de manera más sencilla, el efecto aproximado de cada variable sobre el índice de felicidad.

5.3 Reflexión profesional

Más allá de los números, este proyecto muestra cómo se puede abordar una pregunta social (la felicidad en los países) desde una perspectiva de **analítica de datos**. No se trata solo de predecir un valor, sino de entender qué hay detrás, qué patrones se repiten y qué factores parecen estar más ligados al bienestar de las personas.

El uso de un **dashboard en Streamlit** añade un valor extra, porque permite que personas que no programan puedan interactuar con los modelos, ajustar parámetros y explorar escenarios hipotéticos. Esto convierte el trabajo en algo más cercano a una herramienta de apoyo a la decisión que a un ejercicio puramente académico.

Como trabajo futuro, se podría:

- Incorporar datos de varios años para analizar tendencias en el tiempo.
- Probar modelos de regresión regularizada como Ridge y Lasso.
- Implementar validación cruzada más exhaustiva y una búsqueda más sistemática de hiperparámetros.
- Extender el dashboard para comparar grupos de países según distintas regiones o niveles de ingreso.

En conjunto, el proyecto deja claro que la felicidad de un país no depende de un solo factor, sino de una combinación de elementos económicos, sociales y de percepción. Los modelos no son perfectos, pero sí permiten acercarnos a una comprensión más estructurada y basada en datos de este fenómeno.

REFERENCIAS

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.

Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.

Helliwell, J. F., Layard, R., & Sachs, J. (2019). *World Happiness Report 2019*. Sustainable Development Solutions Network.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95.

James, G., Witten, D., Hastie, T., & Tibshirani, T. (2021). *An introduction to statistical learning: With applications in R* (2nd ed.). Springer.

Kaggle. (2019). *World Happiness Report 2019 (dataset)*. Recuperado de <https://www.kaggle.com>

McKinney, W. (2018). *Python for data analysis: Data wrangling with pandas, NumPy, and IPython* (2nd ed.). O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Streamlit Inc. (2024). *Streamlit documentation*. Recuperado de <https://docs.streamlit.io>